

REVISIÓN:

Simulación del caudal en España utilizando redes neuronales Long Short-Term Memory

El artículo bajo revisión realiza un estudio hidrológico en España a nivel nacional utilizando una herramienta en auge para dicho fin, como es el modelo LSTM. Además, realiza una interesante inclusión de una base de datos en un repositorio internacional, donde se incluyen datos hidrometeorológicos, estáticos e hidrológicos de las estaciones de aforo consideradas en el estudio.

De acuerdo con mis observaciones, el artículo me ha parecido en líneas generales muy interesante y útil. Trata un tema muy innovador como es el empleo de redes neuronales en la simulación de variables hidrológicas, además de dar valor a la baja representación de las cuencas españolas en estudios europeos debido a su heterogeneidad. Sin embargo, recomiendo una serie de mejoras para una mayor claridad del tema en cuestión y de los procedimientos llevados a cabo.

Lista de comentarios según secciones:

Introducción

1. Se introduce cronológicamente el empleo de los modelos basados en procesos físicos, sus limitaciones y, por ello, la necesidad en la introducción de otro tipo de metodologías como son las redes neuronales. Este apartado menciona estudios de comparación entre modelos LSTM y modelos de procesos, pero no incluye referencias, las cuales me parecen esenciales para justificar las ventajas que se defienden en el texto.
2. Se recomienda incluir bibliografía más reciente en la introducción sobre modelos basados en datos, ya que es un tema muy reciente y en auge.

Materiales y métodos

3. La figura 2 se menciona como una representación de la zona de estudio. En ella se muestran los límites de las distintas demarcaciones hidrográficas, pero no se indica el nombre y la posición de cada una de ellas.
4. En el subapartado 'Ampliación de CAMELS-ES: EMO1 y EFAS5' debería de especificarse mejor qué es EFAS y qué es LISFLOOD-OS. Además, no queda muy claro cuáles son los parámetros de entrada de LISFLOOD-OS, ¿a qué 14 parámetros del modelo se refiere?
5. Se menciona el conjunto de datos EMO1, pero la bibliografía citada dirige al conjunto de datos EMO-5.
6. En el subapartado 'Simulación del caudal con LSTM' debería introducirse la metodología LSTM. A pesar de la bibliografía citada, la cual incluye varias descripciones del modelo LSTM, seguimos ante un modelo innovador aplicado a la hidrología. Una breve descripción que explique las características de dicha red es necesaria para entender por qué se utiliza esta red neuronal, y no otra. La descripción que se realiza en el primer párrafo de dicho apartado es pobre y poco explicativa para un público que no conozca esta red.
7. En el subapartado 'Simulación del caudal con LSTM' se reserva un párrafo para comentar los hiperparámetros utilizados en la red. Se habla sobre la capa totalmente conectada con activación lineal (FC) y se indica que su número de nodos es un parámetro a ajustar. El parámetro a ajustar no está relacionado directamente con esta última capa, sino con

- la capa LSTM, donde se define el número de neuronas, o de nodos, como hiperparámetro para la optimización de la red. Si se decide que el número óptimo es de 128 nodos, entonces de la red LSTM se obtendrán 128 celdas de estado (hidden state), las cuales posteriormente son la entrada (128) a la capa con activación lineal. Se recomienda que modifiquen este párrafo y dejen claro el funcionamiento de la red.
8. Siguiendo con los hiperparámetros, ¿qué es el límite de los gradientes normalizados?
 9. En la ecuación 1, la ecuación del NSE, falta el subíndice que representa el caudal simulado.
 10. En el subapartado 'Simulación del caudal con LSTM', existe otro subapartado titulado 'Simulación del caudal observado con LSTM'. Creo que puede ser confuso y podría cambiarse este último título a 'Modelo puro LSTM' o similar. Además, el siguiente subapartado 'Emulador LSTM del modelo LISFLOOD-OS', también se podría cambiar para que encaje con el anterior: 'Modelo subrogado LSTM de LISFLOOD-OS' o similar.
 11. Las tablas 1 y 2 pueden agruparse en una, incluyendo una columna que indique si la variable es estática o dinámica. Lo mismo para las tablas 3 y 4. Además, las tablas 3 y 4 se encuentran mal citadas. Por ejemplo: '... se utilizan las series de precipitación, temperatura y evapotranspiración de EMO1 (Tabla 3) ...'. En este caso, la tabla citada debería ser la 4.
 12. Error gramatical: 'La variable objetivo siguen siendo ... '. Debería ser 'sigue'.
 13. Para una mayor claridad e igualar la explicación del modelo puro LSTM con el modelo subrogado, sería interesante incluir un esquema explicativo del procedimiento del modelo.

Resultados

14. Dentro de los resultados obtenidos del primer modelo LSTM, aquel cuya variable objetivo es el caudal observado en las estaciones de aforo, se menciona que existe sobreajuste en las tres muestras de entrenamiento, validación y prueba. En la figura 4 no se observa ningún comportamiento que valide esa afirmación. Además, no queda claro si el resultado del KGE mediano de 0.69 es anterior a las modificaciones realizadas para solventar ese supuesto sobreajuste.
15. Se comenta que en la cuenca del río Júcar existe una diferencia negativa en el rendimiento en comparación con las demás demarcaciones. El bajo rendimiento de la simulación de caudal en estaciones del río Júcar con el modelo LSTM podría ser también debido a la baja representación de estas estaciones con estas características hidrometeorológicas concretas (cuenca mediterránea). La generalización del modelo LSTM ha podido eliminar la información de estas estaciones con baja representación.
16. En la figura 5 debería aparecer la línea de referencia del rendimiento de EFAS, al igual que se realiza en la figura 4.

Referencias

17. El artículo de Knoben et al. (2019) fue incluido en las referencias, pero nunca citado en el texto.